人工智能基础 Cheating sheet

自86 相良儒

图搜索策略

- 宽度优先、深度优先
- 等费用搜索法

$g(n_{init})=0$, $g(n)=g(m)+C(m,n)$, 在open表中节点按$g(n)$排序

- 爬山法：与图搜索节点的距离 扩$h(n)$至open表中排序
- 启发式搜索 $f(n)=g(n)+h(n)$排序. A^*: $h(n)\le h^*(n)$

最终的问题

完备性：如果问题解算法就一定能找到可采纳性：不漏掉最优的解中的角，找最优解

问题的形式描述

(1)一个抽象问题描述

(2)把问题变成子问题的算符

(3)一般表示问题描述

- 与或图

与或图上搜索与图搜索的区别

- 解图：由解节点构成的子图
- 与或图的搜索：BFS, DFS, 有序搜索

例 图 f^*

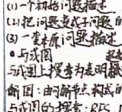

博弈树搜索

极大极小搜索法：在每个内部节点上 α-β剪枝：这些结点一定剪掉

- α代表：极小节点，β值≤任何极大祖先α值.
- β代表：极大节点，α值≥任何极小祖先β值.

α-β搜索效率

设深度为D，每个节点有B个后继

N_D：所有结点总数之值.

- 穷尽：$N_D=2B^D-1$
- 理想：$N_D=B^{\frac{D}{2}}+B^{\frac{D}{2}}-1$

逻辑十罗辑搜索

假设正确一搜索全树.

1. 选择 从根节点开始，逐层选择最优的子节点，直到达到叶子节点. 级联规则：每次为新叶子节点的后代规则应用前向链收集，N步后得叶子规则，因节点扩展的不规则，没有子节点：$T_j=U_j+C\sqrt{\frac{\log N}{N_j}}$
2. 扩展 不能扩展则扩展之
3. 模拟
4. 反向传播：更新沿着路径从开始到结束路径上的N_j, U_j, T_j

对抗搜索性质定理

- 阶段问题：有多项式时间算法解决的对抗问题.

NP类问题：对一个问题的猜想 给定解决时间算法验证的判定问题.

$P\subseteq NP$

NP完全：判定问题$P\in NP$, 对所有其他判定问题$P'\in NP$, 有$P'\le P$, 则P是NP完全的 (NP问题的难度)

NP难度

Theo: $P_1, P_2\in NP$, 若P_1是NP完全, $P_1\le P_2$, 则P_2是NP难度.

(一下证明所有的都同理)

NP难题

$P_1\le P_2$, $P_1\in NP$, 则P_2是NP难的 (不要$P_2\in NP$是否完全)

谓词逻辑与归结原理

合取范式

基本值式：$A\to B\Leftrightarrow \neg A\vee B$

$A\leftrightarrow B\Leftrightarrow (A\to B)\wedge(B\to A)$

$A\to B\Leftrightarrow \neg B\to \neg A$

扩张律：$(A\to B)\wedge(A\to \neg B)\Leftrightarrow \neg A$

正则：简单析取式

子句集：析取式形式子句集合

合取范式：$(\vee)\wedge(\vee)$

析取范式：$(\wedge)\vee(\wedge)$

推理规则

假言推理：$\{(A\to B)\wedge A\}\Rightarrow B$

拒取式：$\{(A\to B)\wedge\neg B\}\Rightarrow \neg A$

析取三段论：$\{(A\vee B)\wedge\neg A\}\Rightarrow B$

假言三段论：$\{(A\to B)\wedge(B\to C)\}\Rightarrow (A\to C)$

假言行三段论：$\{(A\to B)\wedge(B\to C)\wedge A\}\Rightarrow (A\to C)$

构造性二值：$(A\to B)\wedge(C\to D)\wedge(A\vee C)\Rightarrow (B\vee D)$

eg: 证明：

前提 $P\vee q$, $p\to \neg r$, $s\to t$, $T\wedge s\to r$, $\neg t$.

结论 q.

证明：

① $s\to t$ 前提引入 ② $\neg t$ 前提引入

③ $T\wedge s\to r$ 前提引入

④ r ③ ② 假言推理

⑤ $p\to \neg r$ 前提引入

⑥ $\neg p$ ④ ⑤ 拒取式

⑦ $P\vee q$ 前提引入

⑧ q ⑥ ⑦ 析取三段论

归结原理

$P\vee q$, $\neg q\vee r\Rightarrow p\vee r$

谓词逻辑基础

个体常量：a, b, c, d.

个体变元：x, y, z.

谓词常量：P, Q, R, T.

谓词变量：$P(x), Q(x,y), R(x,b)$

$\neg P(x)=P(x)$

$P(x)\to Q(x)=\neg P(x)\vee Q(x)$

$\neg(\forall x)P(x)=\exists x(\neg x)\neg P(x)$

$\neg(\exists x)P(x)=\forall(\neg x)\neg P(x)$

$(\forall x)(P(x)\vee Q)=\forall x\, P(x)\vee Q$

$(\exists x)(P(x)\vee Q)=(\exists x)P(x)\vee Q$

$(\forall x)(P(x)\wedge Q)=\forall x\, P(x)\wedge Q$

$(\exists x)(P(x)\wedge Q)=\exists x\, P(x)\wedge Q$

$(\forall x)(P\to Q)=\exists x\, P\to Q$

$(\exists x)(P(x)\to Q)=\forall x\, P(x)\to Q$

$(\forall x)(P\to Q(x))=P\to(\forall x)Q(x)$

$(\exists x)(P\to Q(x))=P\to(\exists x)Q(x)$

$(\forall x)(P(x)\wedge Q(x))=\forall x\, P(x)\wedge\forall x\, Q(x)$

$(\exists x)(P(x)\vee Q(x))=\exists x\, P(x)\vee\exists x\, Q(x)$

前束范式

①消$\to$, $\leftrightarrow$ ② 否定深入 ③变量换名 ④量名, 至词前移

谓词逻辑的推理

- 置换 $\forall$消去, $\exists$以某常量替代

归结原理

证 $A\wedge\neg B$ 永假

⑨ $P\vee Q$, $P\to R$, $Q\to S$, 证 $S\vee R$

$(P\vee Q)\wedge(P\to R)\wedge(Q\to S)\wedge\neg(S\vee R)$

$S=\{P\vee R, \neg P\vee R, \neg Q\vee S, \neg S, \neg R\}$

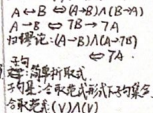

谓词逻辑中的消解原理

寻找互补对数因子.

- 置换：$\{t_i/a_i\}$. t_i代替a_i, a_i为变量, t_i常所, θ, λ, α表示置换.
- 合一：$F_1\theta=F_2\theta=\cdots=F_n\theta$. θ为合一置换.
- 最一般合一：MGU.

α为F的合一置换, 且$\forall\theta$合一, 有 s.t. $\theta=\alpha\cdot\lambda$, 则$\alpha$为$F$的一般合一. (最大公约数, 提炼信息最少)

斯坦林格式：不含$\exists$, 每式均合取范式

eg: $\exists x\,\forall y\,\exists z\, P(x,y,z)\Rightarrow \forall y\, P(a,y,f(y))$

推理

$F=\forall x((P(x)\to(B(x)\wedge R(x)))$

$H=\exists x(P(x)\wedge S(x))$. $G=\exists x(S(x)\wedge R(x))$

证: G为F, H的推论.

证明: $F=(\forall x)(\neg P(x)\vee B(x))\wedge(\forall x)(\neg P(x)\vee R(x))$

$H:\ \exists x(P(x)\wedge S(x))$

$\neg G=\forall x(\neg S(x)\vee\neg R(x))$

$S=\{\neg P(x)\vee Q(x), \neg P(y)\vee R(y), P(a), S(a), \neg S(z)\vee\neg R(z)\}$.

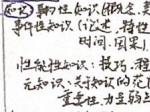

支持量化优先策略

目标公式否定

单元子句优先：优先年文答子句. 不完备.

期待条策略：求真-重复, 被归要.

基于规则的推理

if. then.

正向演绎系统：$L\to W$ (这→公式)

事实表达式的与或树表示：

变换该公式的子句集引作为此与或图的解图的集合; 所得到的子句集作为所因子节点的析取

逆向演绎系统 $W\to L$ (公式→这)

基于规则的系统 (产生式系统)

论证推理 ↔ 拉列条略 → 产生规则

知识表示

- 必要 事物性 知识 (概念、要素) 性质 事件性知识 (过程、特性、现象、时间、因果)

1. 性质性知识：技巧、程序、元知识、关于知识的范围、来源、重要性、力量、弱点、缺陷

表示方法：状态空间方法：1×状态和操作符为基本元；需要扩展过多节点，出现组合爆炸

谓词逻辑方法：产格、灵活、数学优、结构化

产生式规则：完整性、强性、直观性

语义网络：无有让正确性

Is-a > Part-of > if-needed

监督学习

线性回归 $y=wx+b$.

最小二乘：$\min\sum_{i=1}^{n}(y_i-(wx_i+b))^2$

$S_{xx}=\sum_{i=1}^{n}(x_i-\bar{x})(x_i-\bar{x})$.

$S_{xy}=\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})$ $\hat{w}=\frac{S_{xy}}{S_{xx}}$

$S_{yy}=\sum_{i=1}^{n}(y_i-\bar{y})(y_i-\bar{y})$ $\hat{b}=\bar{y}-\hat{w}\bar{x}$

极线性建模 $y_i=w(x_i+b+\varepsilon_i$

$\varepsilon\sim N(0,\sigma^2)$

$f(y_i|w,b,x_i)=\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(y_i-(wx_i+b))^2}{2\sigma^2}\right)$

$f(y|w,b,x)=\prod_{i=1}^{n}f(y_i|w,b,x_i)$ 似然函数.

最大似然估计与最小二乘法结果相同.

但考虑到了数据方差

$Var(\hat{w})=\frac{\sigma^2}{S_{xx}}$

极大似然法 $H_0: w=0$. $H_1: w\neq 0$

$p=2\Phi\left(-\frac{|\hat{w}|}{\sqrt{Var(\hat{w})}}\right)$

平方和的分解 $R^2=\frac{\text{回归的平方和}}{\text{总平方和}}$

$\sum(y_i-\bar{y})^2=\sum(y_i-\hat{y}_i)^2+\sum(\hat{y}_i-\bar{y})^2$

SST RSS Reg.S.

测试方法：独立测试集，随机抽样；多结交叉验证. 留一交叉验证.

评价指标：

$MAE=\sum|y_i-(wx+b)|$

$MSE=\sum(y_i-(wx_i+b))^2$

$RMSE=\sqrt{MSE}$

多项式回归 $y=w_0+w_1x+\cdots+w_mx^m$

$y=Xw$. $y=[y_1, y_2, \cdots y_n]^T$

$X=\begin{bmatrix}1 & x_1 & \cdots & x_1^m\\ 1 & x_2 & \cdots & x_2^m\\ \vdots & \vdots & \ddots & \vdots\\ 1 & x_n & \cdots & x_n^m\end{bmatrix}$ $W=(w_0, w_1\cdots w_m)^T$

$\min(y-\hat{w}x)^T(y-\hat{w}x)\Rightarrow\hat{w}=(X^TX)^{-1}X^Ty$

$\hat{w}\sim N(w, \frac{\sigma^2}{S_{xx}})$, $\hat{b}\sim N(b, \frac{\sigma^2}{nS_{xx}}\sum x_i^2)$

$Y_0\sim N(wx_0+b, \sigma^2(1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}))$

正则化 $\min(y-Xw)^T(y-Xw)+\lambda f(w)$

岭回归：$f(w)=\|w\|_2$

Lasso：$f(w)=\|w\|_1$

Best subset $f(w)=\|w\|_0$

Elastic net $f(w)=\lambda_1\|w\|_1+\lambda_2\|w\|_2$

Logistic 回归

Probit: $\Phi(x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$

Logit: $f(x)=\frac{1}{1+e^{-x}}$

$\log\frac{P(Y=1)}{1-P(Y=1)}=wx+b$

$\pi(x)=\frac{1}{1+\exp(-wx-b)}$ $\frac{d\pi}{dx}=w\pi(x)\cdot[1-\pi(x)]$

优化推断：

$f(y|w,b,x)=\prod_{i=1}^{n}f(y_i;w,b,x_i)$

$=\prod_{i=1}^{n}(\pi(x_i))^{y_i}(1-\pi(y_i))^{1-y_i}$

$L(w,b|x,y)=\prod_{i=1}^{n}(\pi(x_i))^{y_i}(1-\pi(x_i))^{1-y_i}$

最大化L以及函数

交叉熵：$\min-\frac{1}{n}\sum_{i=1}^{n}(y_i\log\pi(x_i)+(1-y_i)\log(1-\pi(x_i)))$

梯度下降 $x^{new}=x-\alpha f'(x)$

随机梯度下降 一次算一个

$\min-(y_i\log\pi(x_i)+(1-y_i)\log(1-\pi(x_i)))$

测试方法

		Truth	
		Positive	Negative
Predict	阳	TP	FP
	阴	FN	TN

true positive rate $=TP/(TP+FN)$

false positive rate $=FP/(TN+FP)$

true negative rate $=TN/(TN+FP)$.

false negative rate $=FN/(TP+FN)$

敏感性 = true positive rate

特异性 = true negative rate

$Recall=TP/(TP+FN)$

$Precision=TP/(TP+FP)$

Fall-out $=FP/(TP+FP)$

F1-measure $=\frac{2\times Precision\times Recall}{Precision+Recall}$

$ACC=\frac{TP+TN}{TP+TN+FP+FN}$

$BER=\frac{1}{2}\left[\frac{FP}{FP+TN}+\frac{FN}{FN+TP}\right]$

Softmax 回归

$P(Y=k)=\frac{e^{w_kx+b_k}}{\sum_{j=1}^{J}e^{w_jx+b_j}}$

$\log\frac{P(Y=1)}{1-P(Y=1)}=wx+b$.

正则化：

$\min-\frac{1}{n}\sum_{i=1}^{n}\sum_{k=1}^{L}y_{ik}(\log\pi_k(x_i))+\lambda f(w)$.

前馈神经网络

输入单元、线性单元：

$z=w^Tx+b$. $a=z$.

$\frac{da}{dz}=1$, $\frac{\partial z}{\partial b}=1$. $\frac{\partial z}{\partial w}=x^T$

$\frac{\partial\tilde{z}}{\partial b}=1$. $\frac{\partial\tilde{z}}{\partial w}=x^T$

Logistic 单元：$a=\frac{1}{1+e^{-z}}$

$z=w^Tx+b$

$\frac{da}{dz}=a(1-a)$. $\frac{\partial z}{\partial b}=1$ $\frac{\partial a}{\partial b}=a(1-a)$

$\frac{\partial z}{\partial w}=x^T$ $\frac{\partial a}{\partial w}=a(1-a)x^T$

Softmax 回归 $z_i=w_iTx+b_i$

$\pi_i=e^{z_i}\left(\sum_{k=1}^{J}e^{z_k}\right)^{-1}$

$C=-\sum_{k=1}^{J}y_k(\log\pi_k$

$\frac{\partial C}{\partial z_i}=\pi_i-y_i$

$\frac{d\pi}{dz_i}=(\pi_i-y_i)x$

$\frac{d\pi_k}{dz_i}=\begin{cases}\pi_i(1-\pi_i) & k=i\\ -\pi_i\pi_k & k\neq i\end{cases}$

双曲正切单元 $a=\frac{e^z-e^{-z}}{e^z+e^{-z}}$

$\frac{da}{dz}=(1+a)(1-a)$

正则化

强化学习

马尔可夫过程

状态转移概率：$P_{ss'}=P(S_{t+1}=s'|S_t=s)$

状态转移矩阵：

$P=\begin{pmatrix}P_{11} & \cdots & P_{1n}\\ \vdots & & \vdots\\ P_{n1} & \cdots & P_{nn}\end{pmatrix}$ 从行转移到列 $\sum_{s'=1}^{n}P_{ss'}=1$

马尔可夫回报过程 $G_t=R_t+\gamma G_{t+1}$

$v(s)=E[G_t|S_t=s]$

$r_s=E[R_{t+1}|S_t=s]$

状态价值函数：

$V(s)=r_s+\gamma\sum_{s'\in S}P_{ss'}v(s')$

$v=r+\gamma Pv$.

$V=(I-\gamma P)^{-1}v$

马尔可夫决策过程

$S=\{s_1, \cdots s_n\}$. $A=\{a_1, \cdots a_m\}$.

$P=(p_{s'}^a)_{n\times m}$, $R=(r_s^a)_{n\times m}$

$r_s^a=E[R_{t+1}|S_t=s, A_t=a]$

策略是更稳定！

$\pi(a|s)=P(A_t=a|S_t=s)$

$P^\pi(S_{t+1}=s'|S_t=s)$

$=\sum_{a\in A}\pi(a|s)p_{s'}^a$

$r_s^\pi=\sum_{a\in A}\pi(a|s)r_s^a$

状态价值与行动价值

$V_\pi(s)=\sum_{a\in A}\pi(a|s)q_\pi(s,a)$

$q_\pi(s,a)=E_\pi[G_t|S_t=s, A_t=a]$

贝尔曼期望方程 (区别π是相同的)

$V_\pi(s)=\sum_{a\in A}\pi(a|s)\left[r_s^a+\gamma\sum_{s'\in S}p_{ss'}^a v_\pi(s')\right]$

$q_\pi(s,a)=r_s^a+\gamma\sum_{s'\in S}p_{ss'}^a\sum_{a'\in A}\pi(a'|s')q_\pi(s',a')$

矩阵：$v_\pi=(I-\gamma P^\pi)^{-1}r^\pi$

预测问题：计算价值，评价策略

控制问题：优化价值，寻优策略.

基于值函数 状态转移模型：

强化：拉制：

线性方程 策略迭代

动态规划 价值迭代

动态规划 $V^{(k+1)}=r^\pi+\gamma P^\pi V^{(k)}$

策略评价算法：

Initialize $V(s)$, arbitrarily except $V(\text{term})=0$

Loop:

$\Delta\leftarrow 0$

Loop for each $s\in S$:

$v\leftarrow V(s)$

$V(s)\leftarrow\sum_a\pi(a|s)\sum_{s',r}p(s',r|s,a)[r+\gamma V(s')]$

$\Delta\leftarrow\max(\Delta, |v-V(s)|)$

until $\Delta<\theta$

最优策略：

$\pi_*\ge\pi'$: 当$V_\pi(s)\ge V_{\pi'}(s)$

$V_*(s)=\max_\pi V_\pi(s)$

$q_*(s,a)=\max_\pi q_\pi(s,a)$

策略迭代：

$\pi\to v\to\pi\to v\to\cdots$

贝尔曼最优方程.

$V_*(s)=\max_{a\in A}\left(r_s^a+\gamma\sum_{s'\in S}p_{ss'}^a v_*(s')\right)$

$q_*(s,a)=r_s^a+\gamma\sum_{s'\in S}p_{ss'}^a\max_{a'\in A}q_*(s',a')$

价值迭代

$V_{k+1}(s)=\max_{a\in A}\left(r_s^a+\gamma\sum_{s'\in S}p_{ss'}^a V_k(s')\right)$

策略提取：

$\pi_*(s)=\arg\max_{a\in A}\left(r_s^a+\gamma\sum_{s'\in S}p_{ss'}^a V_*(s')\right)$

同步迭代：算完所有状态一次更新

异步迭代：算完第一个更新一个

蒙特卡洛

Input a policy π.

Initialize: $V(s)\in R$. Returns(s) ← empty list

Loop forever:

Generate an episode following π: $S_0, A_0, R_1, \cdots$

$G\leftarrow 0$

Loop for each step of episode: $t=T-1, T-2, \cdots 0$

$G\leftarrow\gamma G+R_{t+1}$

Unless S_t appears in $S_0, S_1, \cdots S_{t-1}$: (首次访问 / 每次访问)

Append G to Returns(S_t)

$V(S_t)\leftarrow$ average(Returns(S_t))

Input: π. $\alpha\in(0,1]$

Initialize $V(s)$ except $V(\text{terminal})=0$

Loop for each episode:

Initialize S

Loop for each step of episode:

$A\leftarrow$ action by π for S.

Take action A, observe R, S'.

$V(S)\leftarrow V(S)+\alpha[R+\gamma V(S')-V(S)]$

$S\leftarrow S'$

until S is term

时序差分

$V(S_t)\leftarrow V(S_t)+\alpha[R_{t+1}+\gamma V(S_{t+1})-V(S_t)]$

$G_t\approx R_{t+1}+\gamma V(S_{t+1})$

增益式 需将卡洛预测.

$V(S_t)\leftarrow V(S_t)+\frac{1}{k}(G_t-V(S_t))$

$k\leftarrow k+1$

定步长蒙特卡洛预测

$V(S_t)\leftarrow V(S_t)+\alpha(G_t-V(S_t))$

eg: 化为析取范式:

$((\forall x)F(x,y)\to(\exists y)G(y))\to(\forall x)H(x,y)$

① 消蕴涵

② 深入否定

③ 换名量词防冲突

④ 析取量词

$\Leftrightarrow \neg(\neg((\forall x)F(x,y)\vee(\exists y)G(y)))\vee(\forall x)H(x,y)$

$\Leftrightarrow ((\forall x)F(x,y)\wedge\neg(\exists y)G(y))\vee(\forall x)H(x,y)$

$\Leftrightarrow ((\forall x)F(x,m)\wedge(\forall y)\neg G(y))\vee(\forall z)H(z,m)$

$\Leftrightarrow ((\forall x)F(x,m)\vee(\forall z)H(z,m))\wedge((\forall y)\neg G(y)\vee(\forall z)H(z,m))$

$\Leftrightarrow (\forall x)(\forall z)(\forall y)((F(x,m)\vee H(z,m))\wedge(\neg G(y)\vee H(z,m)))$

eg: 前提: $\forall x(P(x)\to Q(x))$, $P(a)$.

结论: $Q(a)$

证明: ① $\forall x(P(x)\to Q(x))$ 引入前提

② $P(a)$ 引入前提

③ $P(a)\to Q(a)$ 对特称量词

④ $Q(a)$ ③的假言推理.

eg: 事实: A∨B. 目标: C∨D. 规则: A→C∧D. B→E∧G

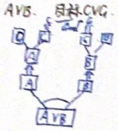

eg: 事实: F1: S(class2, a): a是班级class2的学生

F2: T(class2, b): b是班级class2的老师.

规则: R1: $S(z,y)\wedge T(z,x)\to TofS(x,y)$

TofS(x,y): x是y的老师.

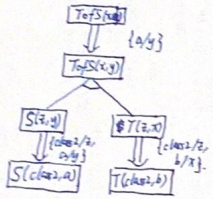

eg: 用最大似然估计法推导泊松分布模型的参数w.

泊松分布: $P(Y=k)=\frac{\mu^k\cdot e^{-\mu}}{k!}$, $k=0,1,2,\cdots$

其概率密度函数为: $f(Y)=\frac{\mu^Y e^{-\mu}}{Y!}$.

设 $\log E(Y)=w^Tx$, $\mu=e^{w^Tx}$

似然函数: $L(w,b|x,y)=\prod_{i=1}^{n}f(Y^{(i)})=\prod_{i=1}^{n}\frac{\mu^{y_i}\cdot e^{-\mu}}{y_i!}$

取对数: $l(w,b|x,y)=\log L(w,b|x,y)$

$=\sum_{i=1}^{n}y_i(w^Tx_i)-\sum_{i=1}^{n}e^{w^Tx_i}-\sum_{i=1}^{n}(\log(y_i!))$

最大化似然函数: $\frac{\partial l}{\partial w}=0$, 令导数为0

$\therefore \sum_{i=1}^{n}x_i(y_i-e^{w^Tx_i})=0$

时序差分学习

SARSA: 根据当前的Q求其值.

Initial Q(s,a), Q(term,·)=0.

Loop for each episode:

Initialize S.

choose A from S using policy from Q. 对所有的

Loop for each step of the episode: (E-greedy)

take action A, observe R, S'. 当前状态

choose A' from S' (policy from Q. E-greedy)

$Q(S,A)\leftarrow Q(S,A)+\alpha[R+\gamma Q(S',A')-Q(S,A)]$

$S\leftarrow S'; A\leftarrow A'$

until S is terminal.

Q-learning 根据当前的最大的Q之值.

期望SARSA: 考虑到目标策略得到的期望

$Q(S_t,A_t)\leftarrow Q(S_t,A_t)+\alpha(R_{t+1}+\gamma\sum_{a\in A}\pi(a|S_{t+1})Q(S_{t+1},a)-Q(S_t,A_t))$

根据策略的概率值.